工业缺陷小样本检测综述
——前世今生、方法脉络与改进方向

> 本综述基于 2025 年 7 月前公开文献，面向航空构件、车漆等工业场景的小样本缺陷检测研究，系统梳理发展脉络、方法继承关系与未解瓶颈，为后续改进研究提供基础。

一、第一性原理：为什么工业缺陷检测是个困难问题

在讨论所有方法之前，先从第一性原理理解问题的本质。

1.1 问题的物理本质

工业缺陷检测的困难不是"算法不够好"，而是**信息论意义上的不对称**：

```
正常品样本：大量（生产线每天产出）
缺陷样本：极少（缺陷本来就是低概率事件）
新缺陷类型：零样本（从未见过）

这意味着：
  传统监督学习的基本假设（每类样本充足）在这里不成立
  模型需要在"见过很少"的情况下做出"可靠判断"
```

1.2 工业场景的四个特殊约束

约束	说明	影响
数据稀缺	缺陷样本天然稀少，标注需专家	大规模监督训练不可行
类别动态	新材料/新工艺引入新缺陷类型	模型需要快速适应
跨域偏移	不同设备/光照/材质条件变化	训练域到测试域性能急降
实时性要求	产线节拍约束，推理必须快	大模型部署困难

这四个约束共同指向同一个研究方向：**少样本、快速适应、跨域泛化**。

二、发展脉络：从规则到学习（2000—2025）

2.1 第一阶段：传统图像处理（2000—2014）

核心方法：

- **手工特征提取**：Gabor 滤波器检测纹理异常、小波变换提取频域特征、灰度共生矩阵（GLCM）建模纹理统计。
- **统计模型**：高斯混合模型（GMM）建模正常分布，异常点检测为离群值。
- **模板匹配**：与标准模板的像素级对比，适合形状固定的产品。

代表性应用与效果：

领域	方法	效果	局限
纺织品（布匹）	Gabor 滤波器	规则缺陷检出率>90%	光照变化敏感
钢板	统计阈值	宏观划痕>95%	无法检测微细缺陷
PCB	模板匹配	确定性缺陷>98%	需精确对齐

方法瓶颈：

- 手工特征依赖领域专家知识，跨产品迁移代价高。
- 对光照变化、背景纹理变化鲁棒性差。
- 无法处理未见过的缺陷形态（开集问题）。

2.2 第二阶段：深度监督学习（2015—2019）

触发事件：AlexNet（2012）证明 CNN 能自动学习层次特征，ImageNet 竞赛引发深度学习革命。

核心范式演进：

```
CNN 分类（ResNet, VGG）→ 目标检测（Faster R-CNN, YOLO）→ 语义分割（U-Net, DeepLab）
```

代表性工作：

- **Masci et al. (2012)**：首次证明 CNN 在钢铁表面缺陷分类上超越手工特征，开创 CNN 用于工业检测的先河。
- **NEU 表面缺陷数据集（东北大学，2015）**：6 类钢材表面缺陷，1800 张图，成为领域基准数据集，此后大量工作在此验证。
- **YOLO 系列（2016—至今）**：实时目标检测，产线部署可行，成为工业检测事实标准骨干之一。
- **U-Net（2015）**：编码器-解码器结构，擅长像素级缺陷定位，在半导体和医疗领域大量采用。

典型性能指标（NEU 数据集）：

方法	准确率	速度	说明
CNN（ResNet-50）	97-99%	~20ms	6 类分类，全监督
YOLO（检测）	mAP>80%	<10ms	同时定位+分类
U-Net（分割）	IoU>70%	~50ms	像素级定位

方法瓶颈（关键！）：

- 需要**数千—数万**张标注样本。
- **封闭集假设**：测试类别必须在训练集中出现。
- 新产品/新缺陷类型出现时，需要**重新收集数据+重新训练**，成本极高（数周—数月）。
- **跨域泛化差**：在 A 工厂训练的模型，直接用于 B 工厂效果急剧下降。

这正是整个后续研究要解决的核心问题。

2.3 第三阶段：迁移学习与领域适应（2019—2021）

问题背景：深度监督学习在大数据集上有效，但工业场景数据不足。

迁移学习的基本思路：
```
ImageNet 预训练大模型（海量自然图像）
    ↓ 冻结底层特征，微调顶层
工业数据集（少量标注）
    ↓ 适配新领域
工业缺陷检测
```

代表性方法：

- **预训练+微调（Fine-tuning）**：ResNet/VGG 在 ImageNet 预训练，然后在工业数据集小样本微调。Shi et al.的 CTFLCA 实现了跨分布域的高精度适配。
- **领域自适应（Domain Adaptation）**：最小化源域和目标域的特征分布差异（MMD、DANN 等）。
- **知识蒸馏**：大模型→小模型，维持精度的同时降低部署成本。

效果与局限：

方法	适用场景	典型提升	瓶颈
Fine-tuning	目标域有 100+标注样本	+10-20% vs 从零训练	<10 样本时

过拟合 |
| 领域自适应 | 源目标域类别相同 | 跨域性能+5-15% | 类别不同时无效 |
| 知识蒸馏 | 大模型→边缘部署 | 参数量-70%，精度损失<5% | 需要完整训练集 |

本质瓶颈：迁移学习仍然假设**目标域有一定量标注数据**，无法解决"新缺陷类型、只有 5 张图"的场景。

2.4 第四阶段：异常检测范式兴起（2018—2023）

核心思路转换：与其学"缺陷长什么样"，不如学"正常品长什么样"，偏差即为异常。

这个思路对工业场景有特别价值：
- 正常品样本充足（生产线每天大量产出）
- 缺陷样本极少且多变
- 无需事先定义缺陷类别

方法演进：

```
一类分类（SVDD, 2001）
    ↓
自编码器重建误差（2018—2020）
    ↓
预训练特征+记忆库（SPADE, PaDiM, 2020—2021）
    ↓
PatchCore（补丁级记忆库，2022）← 里程碑
    ↓
生成对抗/扩散模型辅助（2022—2024）
    ↓
视觉语言模型（WinCLIP, AnomalyCLIP, 2023—2024）
```

里程碑方法详解：

PatchCore（Roth et al., CVPR 2022）：
- 方法：用预训练 ResNet 提取补丁级特征，构建正常品的记忆库，推理时计算测试图像到记忆库的距离。
- 性能：MVTec-AD 数据集上图像级 AUROC **99.1%**，像素级 AUROC **98.1%**。
- 优势：无需异常样本，只用正常品训练，可冷启动。
- 局限：内存开销大（记忆库随正常样本数增长），无法识别缺陷的精确类型。

WinCLIP（Jeong et al., CVPR 2023）：

- 方法：利用 CLIP 的视觉-语言对齐，用文本描述（"a photo of a scratch"）进行零样本异常检测。
- 性能：MVTec-AD 零样本 AUROC **91.8%**，无需任何训练样本。
- 意义：**首次实现真正零样本的工业缺陷检测**，开创视觉语言模型用于工业检测的新范式。

AnomalyCLIP（Zhou et al., ICLR 2024）：
- 在 WinCLIP 基础上学习对象无关的文本提示，在 17 个数据集上强泛化。
- 意义：通用异常检测能力，单模型跨领域。

异常检测的性能基准（MVTec-AD）：

方法	图像 AUROC	像素 AUROC	需标注缺陷	年份
SPADE	85.5%	96.5%	否	2020
PaDiM	97.9%	97.5%	否	2020
PatchCore	99.1%	98.1%	否	2022
WinCLIP（零样本）	91.8%	-	否	2023
AnomalyCLIP（零样本）	91.5%	-	否	2024

异常检测的局限性（关键！）：
- 只能判断"正常 vs 异常"，**无法区分缺陷类型**（如 scratch vs dent vs crack）。
- 对于需要区分多类缺陷的维修决策场景（如航空构件不同缺陷对应不同维修方案），能力不足。
- 领域切换时需重新构建记忆库，维护成本高。

2.5 第五阶段：小样本学习与元学习（2020—2025）

背景：解决"区分缺陷类型+只有少量标注样本"的组合问题。

方法大类：

2.5.1 度量学习方法（Metric-based）

核心思路：学习一个好的嵌入空间，使同类缺陷相似、异类缺陷差异大，推理时用距离分类。

方法	原型构建	分类方式	论文
Prototypical Networks	支持集均值特征	欧氏距离	Snell et al., NeurIPS 2017
Matching Networks	全部支持样本	注意力加权	Vinyals et al., NeurIPS 2016

| **Relation Networks** | 可学习关系模块 | 关系分数 | Sung et al., CVPR 2018 |
| **TADAM** | 任务条件化原型 | 欧氏距离 | Oreshkin et al., NeurIPS 2018 |

ProtoNet 的工业应用性能（典型值）：

- NEU 钢材缺陷（5-way 5-shot）：**~82-86%**
- MVTec-FS（5-way 5-shot）：**~70-78%**
- 航天叶片（本项目，2-way 5-shot）：**85.2%**（已验证）

优势：对任务多样性依赖较低，特征质量够好时效果稳定。
局限：特征空间质量高度依赖预训练骨干网络的质量。

2.5.2 梯度优化方法（Optimization-based / MAML 族）

核心思路：学习一个好的模型初始化参数 θ_0，使得从 θ_0 出发，用少量样本做几步梯度更新，就能快速适配新任务。

方法	特点	论文
MAML	二阶梯度，学初始化	Finn et al., ICML 2017
FOMAML	一阶近似，省显存	Finn et al., 2017
ANIL	只更新头部，骨干冻结	Raghu et al., ICLR 2020
Meta-SGD	学学习率	Li et al., 2017
Reptile	更简单的元更新	Nichol et al., 2018
Permute-MAML	工业面缺陷稳定性改进	CIS 2024

MAML 在工业缺陷检测的典型性能：

场景	方法	准确率	说明
金属缺陷（5-way 5-shot）	MAML	~78-84%	NEU 类数据集
航天叶片（2-way 5-shot）	MAML+解冻	68.2%	本项目实验
工业组件（5-way 1-shot）	ANIL	~65-72%	有限表达能力

MAML 的核心优势：理论上具有快速适应任何新任务的能力。
MAML 的核心问题：
- 需要大量多样的元训练任务（数据少时效果差）。
- 二阶梯度计算显存开销大（工程限制）。
- 在任务多样性不足时，性能接近随机（如本项目 domain_0-2 只有 5 个独立 task）。

2.5.3 生成增强方法（Generative-based）

核心思路：用生成模型（GAN/扩散模型）合成缺陷样本，扩充训练集。

方法	生成方式	典型场景
DCGAN + 缺陷数据	对抗生成缺陷纹理	钢材、布匹
CycleGAN	正常→缺陷域转换	产线场景迁移
Stable Diffusion 微调	文本+图像生成	多样化缺陷合成
BladeSynth（物理渲染）	Blender 物理仿真	航空叶片（本项目）

效果对比（文献值）：

增强方式	样本增加量	性能提升	局限
几何变换	4-8×	+2-5%	样本多样性有限
GAN 生成	10-100×	+5-10%	可能引入假阳性
物理仿真（仅 Phase0）	无限	特征质量↑	仿真≠真实，有域差

关键发现（来自本项目实验）：
- 仿真数据**只能用于预训练（Phase0）**，进入元训练反而有害（实验 exp05 证明）。
- 仿真数据价值在于**扩充特征多样性**，而非直接替代真实标注。

2.5.4 预训练视觉语言模型方法（Foundation Model-based，2023—2025）

触发事件：CLIP（OpenAI，2021）证明大规模视觉语言预训练能产生强泛化表征。

代表性工作：

MVREC（Liu et al., AAAI 2025）：
- 方法:AlphaCLIP 作为 Phase0 骨干,结合区域上下文和多视角输入,Zip-Adapter 做少样本适配。
- 应用：MVTec-FS 等工业少样本基准。
- 意义：**将视觉语言大模型引入工业少样本检测，开创新范式**。

NexViTAD（2025）：
- 方法：DINOv2+Hiera 双基础模型，层次适配器融合特征，多任务解码器支持跨域。
- 性能：MVTec-AD 跨域 AUC 97.5%。

Few-shot PCB 检测（PMC 2025）：
- 应用：印刷电路板检测，利用基础模型适配少样本场景。
- 证明：基础模型在高频域偏移场景（相机/光照变化）下显著优于传统 CNN。

基础模型方法的优劣势：

优势	局限
零/少样本泛化强	推理速度慢（不适合严苛产线节拍）
文本指导可解释	需要显著计算资源
跨域迁移好	对细粒度工业缺陷仍有差距
无需大量标注	边缘部署困难

三、方法继承关系图谱



```
        │ 继承：大规模预训练 + 元学习适配
        │ 当前前沿：MVREC, NexViTAD, AnomalyCLIP
        │ 瓶颈：推理效率，边缘部署，细粒度检测
```

四、应用场景分类与典型效果

4.1 金属制造（最成熟）

代表数据集：NEU-CLS（钢材）、DAGM（金属纹理）、MPDD（金属零件）

方法类型	典型性能	生产落地情况
全监督 CNN	96-99%	**大量落地**（钢厂、汽车制造）
异常检测（PatchCore）	AUROC >98%	部分落地（需人工复核）
少样本（ProtoNet）	80-88%	试点阶段
基础模型	85-95%	研究阶段

实际生产应用：宝钢、鞍钢等钢铁企业已大规模部署 CNN-based 视觉检测系统，替代人工目检，检测速度从 30 秒/件提升到 0.1 秒/件，漏检率从 5%降低到 <0.5%。

4.2 半导体/PCB（高精度要求）

代表数据集：MVTec-AD（多类工业品）、PCB-DATASET

指标	全监督	异常检测	少样本
检测精度	>99%	>97%	80-90%
对新缺陷适应	需重训	快速	5-shot 适应
生产节拍要求	<5ms	<20ms	<50ms

产业现状：台积电、英特尔等半导体企业大量采用全监督检测，但新产品导入期（缺少标注数据）是公认痛点，小样本方法正在研究和试点中。

4.3 航空构件（本项目最相关）

代表数据集：AeBAD、BladeSynth、本项目 Aero-engine 数据集

特殊性：
- 安全级别高，漏检代价极大（飞行事故）
- 缺陷样本极稀缺（航空事故本来就少）

- 涡轮叶片等精密部件检测需要内窥镜等特殊设备
- 同时需要 RGB/热像/超声多模态信息

方法	性能	说明
全监督 YOLO	mAP ~60-75%	受限于样本量
异常检测	AUROC ~80-90%	AeBAD 上的结果
本项目（ProtoNet+Phase0）	**85.2%**	2-way 5-shot holdout 终评

产业现状：空客、波音等在探索 AI 辅助检测，但目前仍以人工检测为主，AI 作为辅助工具。监管要求（适航认证）是技术落地的主要障碍之一。

4.4 汽车车漆（本项目 CarDD 场景）

代表数据集：CarDD、SOCAR-Defect

特殊性：
- 保险理赔场景，需要区分不同缺陷类型（dent vs scratch 影响维修方案）
- 图像来自手机拍摄，场景多变
- CarDD 论文报告：状态最好方法的 scratch AP=34%，dent AP=40%，说明数据集本身有难度

方法	Scratch AP	Dent AP	说明
Faster R-CNN	~28%	~35%	CarDD 论文 baseline
YOLOv5	~32%	~38%	全监督检测
本项目（TrackM1 目标）	-	-	2-way 5-shot，目标 68-74%

五、当前未解瓶颈（可创新方向）

这是综述最重要的部分——现有方法在哪里"卡住了"。

5.1 跨域泛化瓶颈（最核心，最有意义）

问题描述：在源域上训练的模型，迁移到目标域（不同设备/材质/光照）时性能急剧下降。

文献数据：
- 航天叶片场景：训练域 domain_0-2 上 LogReg 92%，测试域 domain_3 只有 87%（跨试件偏移）。
- 跨数据集：ASDE→CarDD，即使同样是"划痕"类别，特征空间的对齐也极难（本项目实验：62.5%）。

- NexViTAD(2025)研究显示：现有最好方法在严格跨域场景下性能仍下降 15-25%。

当前方法的局限：
- 领域自适应方法需要目标域无标注样本，在真正的"冷启动"场景下失效。
- 特征对齐方法在视觉外观差异过大时效果有限。
- **本质问题**：跨域时，判别缺陷的特征与场景特有纹理/颜色缠绕在一起，难以分离。

可能的改进方向：
- 因果解耦：将"缺陷内在特征"与"成像条件特征"分离（基于因果图）。
- 物理先验约束：利用缺陷的物理成因（应力集中、材料疲劳）构建先验，增强跨域一致性。
- 多模态融合：RGB+热像+超声的互补信息在跨域场景下比单模态更鲁棒（本项目的多模态方向）。

5.2 任务多样性瓶颈（元学习特有问题）

问题描述：元学习（特别是 MAML）需要大量多样的元训练任务，但工业场景中样本本来就少，导致任务多样性极低。

量化验证（本项目）：
- domain_0-2 合并，只有约 5 个独立的 2-way 5-shot 任务。
- MAML 在如此少的任务上，外环梯度几乎无信息（≈随机初始化）。
- **直接结果**：MAML 在 task 多样性≈5 时性能≈随机猜测（53%）。

ProtoNet 为何在低任务多样性下仍有效（关键洞察！）：
- ProtoNet 的推理不依赖任务多样性。
- 只要特征空间本身可分（LogReg>70%），ProtoNet 就能有效推理。
- **这解释了为什么本项目从 MAML 换到 ProtoNet 提升了 17.3 个百分点**。

文献支持：Kumar et al.（2024）报告，自监督预训练+ProtoNet 在工业缺陷场景达到 89.4%，同时指出 MAML 在低任务多样性场景"不适合替换 ProtoNet"。

可能的改进方向：
- 任务增强（Task Augmentation）：通过虚拟任务构造增加多样性（本综述作者已部分实验，效果有限）。
- 任务感知元学习：用任务编码器提取任务级特征，条件化初始化参数（TADAM 类方法）。
- 不依赖任务多样性的方法：ProtoNet、Matching Networks 等度量方法天然适合。

5.3 细粒度区分瓶颈

问题描述：相似外观的缺陷类型难以区分（如 scratch vs dent），这是 CarDD

数据集上 AP 只有 30-40%的根本原因。

数据支持：
- CarDD 论文：scratch AP=34%，dent AP=40%，即使全监督方法在这两类上也表现不佳。
- 本项目 LogReg 只有 64.5%（vs 航天 87.4%），主要因为 scratch/dent 视觉相似。
- 文献综述：NexViTAD 等新方法在 MVTec 上达到 97%+，但在细粒度场景（如车漆）仍有明显差距。

可能的改进方向：
- 细粒度特征提取：注意力机制聚焦边缘/纹理差异（dent 更多 3D 形状信息，scratch 更多线状特征）。
- 多尺度分析：不同缺陷在不同尺度下的显著性不同。
- 辅助信息融合：dent 在光照角度变化时与 scratch 的区分度显著提高（对抗光照的数据增强）。

5.4 效率与精度权衡（部署瓶颈）

问题描述：基础模型（CLIP/DINOv2 类）精度高，但推理速度和内存消耗无法满足工业产线。

具体数据：

模型	精度	推理速度	内存	产线可行？
PatchCore	99.1% AUROC	~50ms	~4GB	勉强可行
WinCLIP	91.8% AUROC	~200ms	~8GB	不可行
AnomalyCLIP	~91% AUROC	~300ms	~12GB	不可行
ProtoNet+ResNet12	~85% acc	~10ms	<1GB	**可行**
YOLO+全监督	mAP ~80-95%	~5ms	~0.5GB	**可行**

可能的改进方向：
- 知识蒸馏：大模型→轻量模型，保留大模型的泛化能力。
- 量化+剪枝：在精度损失<3%的前提下，推理速度提升 4-8 倍。
- 自适应推理：简单样本用轻量模型，困难样本才调用大模型（级联策略）。

5.5 评估协议不统一（学术问题）

问题描述：不同论文使用不同数据集、不同 N-way K-shot 设置、不同评估指标，导致方法间无法公平对比。

具体问题：
- 有的用 2-way 5-shot，有的用 5-way 5-shot，结果完全不可比。
- 有的用 MVTec-FS，有的用自定义数据集，无法确认哪个方法真的更好。

- **NTIRE 2025 CD-FSOD 挑战赛**（128 支参赛队，696 份提交）是解决这个问题的最新努力。

六、你的研究在这个脉络中的位置

6.1 你做的事情的本质

```
工业小样本缺陷检测的完整链路：

① 领域预训练（Phase 0）
   用相关数据（仿真+真实）学通用缺陷表征
   → 这解决"特征质量"问题

② 元学习（Meta-train）
   用 episodic 任务模拟"新批次/新试件上线"
   → 这解决"快速适应"问题

③ Holdout 评估（Meta-test）
   在严格未见域上 5-shot 测试
   → 这验证"真实可用性"
```

你的贡献在于：**将 Phase0+元学习的两阶段框架，在航空叶片这个高难度、高价值场景下验证了可行性，并系统性地诊断出特征质量 vs 任务多样性这两个独立瓶颈的不同影响**。

6.2 航天场景（已验证，论文贡献点 1）

已实现：
- 从 MAML 冻结（~53%）→ MAML 解冻（68.2%）→ ProtoNet（85.2%）的系统性提升
- 特征可分性诊断（LogReg 87%）揭示了"特征够好，但 MAML 训练方式是瓶颈"的根因
- 证明了"仿真数据只进 Phase0，不进 Meta"的正确设计原则（exp05 证伪了盲目扩域）

创新点：
1. 诊断驱动的协议迭代方法论（LogReg→Meta gap 分析）
2. Phase0 仿真+Meta 真实的两阶段分工原则
3. 在航空小样本场景的系统消融

6.3 车漆场景（进行中，论文贡献点 2）

当前状态：Track2 框架已通，但语义对齐问题导致性能受限（62.5%）。

潜在贡献：
- 验证框架在不同场景（航天→车漆）的可迁移性
- 量化语义一致性对小样本检测的影响（正确设计 vs 错误设计的对比）

七、可出发的改进方向（基于瓶颈分析）

方向 1：特征解耦（高价值，中难度）

针对瓶颈：跨域泛化差

核心思路：显式分离"缺陷不变特征"和"域特异特征"

```python
# 概念设计
features = backbone.encode(image)

# 分解
defect_features = defect_encoder(features)   # 与域无关的缺陷特征
domain_features = domain_encoder(features)   # 与缺陷无关的域特征

# 元学习只用缺陷特征
prototypes = mean(defect_features[support_set])
predictions = nearest_prototype(query_defect_features, prototypes)

# 对抗训练确保解耦
# 最大化：域分类器对 domain_features 的混淆（无法区分不同域）
# 最小化：缺陷分类器对 defect_features 的正确率
```

文献基础：DANN（Domain Adversarial Neural Networks）+ ProtoNet 组合。
预期收益：跨域场景（如 M2）提升 5-10%。

方向 2：物理先验约束的元学习（高价值，高难度）

针对瓶颈：航空/工业场景的物理知识利用不足

核心思路：将缺陷的物理成因（应力集中、热损伤、分层机制）注入元学习的任务表征

```
材料物理参数（密度/导热率/弹性模量）
    ↓ 任务编码器
任务表征 t ∈ R^64
    ↓ 条件化
ProtoNet 的原型计算（不同材料用不同的相似度度量）
```

文献基础：TADAM（Task-Conditioned Adaptive Metric）的思路，结合领域知识。
预期收益：跨材料泛化能力显著提升，新材料 5-shot 适配性能提升。

方向 3：对比预训练替换分类预训练（中价值，低难度，可行性高）

针对瓶颈：Phase0→Meta 接口断层

核心思路：用 SupCon 监督对比学习代替分类头预训练，让 Phase0 的嵌入空间直接适合 ProtoNet 推理

文献支持：SimCLR+ProtoNet（IJSRM 2025）报告 89.4%，对比学习显著改善度量空间质量。

实现成本：低，只需修改 Phase0 的损失函数，与其他模块兼容。

方向 4：多模态融合的非对称权重设计

针对瓶颈：多模态信息利用不充分

核心思路：不同缺陷类型对不同模态敏感度不同（表面划痕→RGB，内部分层→超声，热损伤→热像），应动态分配权重

```
缺陷类型 → 敏感模态映射 → 自适应融合权重
  scratch → RGB 主导 → [0.8, 0.1, 0.1]
  delamination → 超声主导 → [0.1, 0.2, 0.7]
  thermal_damage → 热像主导 → [0.2, 0.7, 0.1]
```

文献基础：本综述作者设计，无直接文献对照（即创新点）。
预期收益：航天多模态场景从 85%提升到 88-92%。

八、重要数据集列表

数据集	领域	规模	类别	任务类型	下载
MVTec-AD	通用工业	5354 张，15 类	多类缺陷	异常检测	官网免费
MVTec 3D-AD	通用工业	2656+1137，10 类	多类	3D 异常检测	官网免费
NEU-CLS	钢材	1800 张，6 类	分类	少样本分类	NEU 官网
DAGM	工业纹理	~6000 张，10 类	分类	缺陷分类	Kaggle
AeBAD	航空叶片	5570 张，4 类	异常检测	跨域检测	GitHub
BladeSynth	叶片（合成）	12500 张，5 类	分类	Phase0 预训练	GitHub
CarDD	车漆	4000 张，6 类	检测+分割	多任务	官网
ASDE	产线表面	~6350，2 类	分类	异常检测	公开
GDXray	X 光（航空）	21100 张，多类	检测	目标检测	GitHub
MVREC 基准	多领域工业	-	多类	FSL benchmark	AAAI 2025

九、关键文献速查表

类型	代表文献	年份	贡献	性能基准
综述	Few-shot defect detection: comprehensive review	2025	全面梳理 FSL 缺陷检测	-
全监督基础	Masci et al., CNN for steel defect	2012	开创 CNN 工业检测	钢材>97%
异常检测	PatchCore (Roth et al.)	CVPR 2022	补丁记忆库，SOTA	MVTec 99.1%
视觉语言	WinCLIP (Jeong et al.)	CVPR 2023	零样本工业检测	MVTec 91.8%
视觉语言	AnomalyCLIP (Zhou et al.)	ICLR 2024	跨领域零样本	17 数据集
基础模型 FSL	MVREC (Liu et al.)	AAAI 2025	AlphaCLIP+FSL	工业 FSL SOTA
对比学习+FSL	SimCLR+ProtoNet	IJSRM 2025	预训练+元学习	89.4%
度量元学习	ProtoNet (Snell et al.)	NeurIPS 2017	原型网络基础	miniImageNet 65.77%(1-shot)
优化元学习	MAML (Finn et al.)	ICML 2017	梯度优化元学习基础	miniImageNet 48.70%(1-shot)
跨域 FSL	NTIRE 2025 CD-FSOD 挑战	CVPR 2025W	跨域少样本检测竞赛	多方法比较
数据集	CarDD (Wang et al.)	TITS 2023	车漆缺陷数据集	YOLOv5:

mAP~55% |
| 数据集 | AeBAD | 公开 | 航空叶片异常检测 | PatchCore AUROC~90% |

十、综述小结：用发展眼光看

10.1 脉络本质

```
每个方法都是对上一代方法瓶颈的回应：

手工特征（泛化差）→ CNN（自动学特征）→ 需大量数据
    ↓
迁移学习（少标注）→ 仍需目标域标注
    ↓
异常检测（只需正常品）→ 无法识别缺陷类型
    ↓
小样本学习(5 张即可)→ 需要任务多样性(元学习)/ 依赖特征质量(ProtoNet)
    ↓
基础模型（强泛化）→ 推理慢，边缘部署难
    ↓
???（下一代）→ 效率+精度+跨域同时兼顾
```

10.2 你的工作在哪里

你做的"Phase0 预训练+ProtoNet 元学习"处于**第五阶段**，瞄准的是：
- 样本稀缺（5-shot）✓
- 新批次快速适配（5-shot holdout）✓
- 多模态信息利用（航天 RGB+热像+超声）→ 进行中

10.3 可以写进综述的核心观点

1. **特征质量是元学习的前提**：LogReg 可分性诊断是系统性判断"是改 Phase0 还是改 Meta"的必要工具。

2. **ProtoNet vs MAML 的选择取决于任务多样性**：任务多样性充足→MAML 有效；任务多样性低→ProtoNet 更稳健。这是本领域少有明确量化的结论。

3. **仿真数据只应进入 Phase0，不应进入 Meta**：违反这个原则（exp05）会因为语义偏移导致性能下降。

4. **语义一致性是设计元学习任务的先决条件**：train 和 test 的类别定义必

须一致，这比算法选型更重要。

5. **当前最大未解问题是跨域泛化**：在真实工业场景中，设备/光照/材质的变化是常态，现有方法的跨域性能仍有明显差距，是最有价值的改进方向。